MINISTERUL EDUCAȚIEI ȘI CERCETĂRII

UNIVERSITATEA TEHNICĂ
DIN CLUJ-NAPOCA

DEPARTAMENTUL DE AUTOMATICA ȘI CALCULATOARE
AUTOMATICA SI INFORMATICA APLICATA

PROIECT INDENTIFICAREA SISTEMELOR

Student: **Daju Bianca Teodora**

Profesor: **Mircea Șusca**

2026

Cuprins

Capitolul 1 Introducere **1**

Capitolul 2 Obiectivele lucrării **4**
2.1 Partea I: Metode Neparametrice (Proiectele 1 și 2) 4
2.2 Partea II: Metode Parametrice (Proiectele 3 și 4) 4

Capitolul 3 Fundamente teoretice: Metode Neparametrice **5**
3.1 **Considerații generale** 5
3.2 **Metoda regresiei liniare** 5
3.2.1 Metoda Celor Mai Mici Pătrate (MCMMP) 6
3.3 Liniarizarea modelului prin metoda logaritmării succesive 6
3.3.1 Modelul procesului fizic 6
3.3.2 Identificarea constantei de timp dominante (T_1) 6
3.3.3 Identificarea constantei de timp secundare (T_2) 7
3.4 Identificarea parametrilor pe baza pulsației la faza de $-\frac{\pi}{2}$ 7
3.5 **Semnale de test Neparametrice** 8

Capitolul 4 Proiect 1: Identificarea sistemelor de ordin II cu poli reali **9**
4.1 Scopul acestui proiect 9
4.2 Descrierea procesului fizic 9
4.3 Modelul propus și pașii experimentali 9
4.3.1 Configurarea simulării 10
4.4 Identificarea Experimentală a Parametrilor 10
4.4.1 Determinarea factorului de proporționalitate (K) 10
4.4.2 Calcularea constantei de timp dominante (T_1) 11
4.4.3 Determinarea constantei de timp secundare (T_2) 12
4.5 Validarea Modelului și Analiza Performanței 13

Capitolul 5 Proiect 2: Identificarea sistemelor de ordin II folosind semnale de tip Chirp **15**
5.1 Scopul acestui proiect 15
5.2 Descrierea procesului fizic 15
5.3 Modelul propus și pașii experimentului 15
5.4 Identificarea experimentală a parametrilor 15
5.4.1 Identificarea parametrilor sistemelor de ordin II cu poli reali . . . 16
5.4.2 Determinarea factorului de proporționalitate K 16
5.4.3 Determinarea parametrilor dinamici (ζ, ω_n) 17
5.5 Validarea modelului și analiza performanței 18

Capitolul 6 Fundamente Teoretice: Metode Parametrice **20**
6.1 Semnalul Pseudo-Aleator Binar (SPAB) 20
6.1.1 Definiție și Caracteristici 20
6.1.2 Generarea Semnalului 20
6.1.3 Proprietăți 20
6.1.4 Principii de Calibrare Teoretică 20

6.2 Structuri de Modele Parametrice 21
6.2.1 Modelul ARX 21
6.2.2 Modelul ARMAX 21
6.2.3 Modelul OE (Output Error) 22
6.2.4 Modelul BJ (Box-Jenkins) 22
6.2.5 Validarea Modelelor Identificate 23
6.2.6 Tehnici de Rafinare a Modelelor 24

Capitolul 7 Proiectul 3-Calibrarea Semnalului SPAB 25
7.1 Scopul lucrării 25
7.2 Studiu de Caz: Convertor DC-DC ridicator de tensiune 25
7.2.1 Descrierea procesului fizic 25
7.3 Proiectarea și Calibrarea Semnalului de Intrare 25
7.3.1 Prametrii Secventei SPAB 25

Capitolul 8 Proiectul4 - Identificarea Parametrica 27
8.1 Scopul lucrării 27
8.1.1 Construirea seturilor de date de identificare și validare 27
8.1.2 Metode de Pre-procesare 28
8.1.3 Alegerea Parametrilor de Structură 28
8.1.4 Analiza Proprietăților Modelelor Valide 30
8.2 Modelul Output Error (OE) 31

Capitolul 9 Sinteza Rezultatelor și Analiza Comparativă 32
9.1 Analiza Comparativă 1: Metode Neparametrice (Circuit Hidraulic) . . . 32
9.2 Analiza Comparativă 2: Metode Parametrice (Convertor DC-DC) 32
9.2.1 Sinteză Metodologică 33
9.2.2 Concluzii Finale 33

Bibliografie 34

Capitolul 1. Introducere

Identificarea sistemelor

Este procesul de creare a unui model care să descrie comportamentul unui sistem dinamic, pe baza datelor experimentale.

Un sistem este o parte a lumii cu o interfață bine definită, asupra căreia acționează semnalele de intrare (comandă și perturbație), și care produce semnale de ieșire.

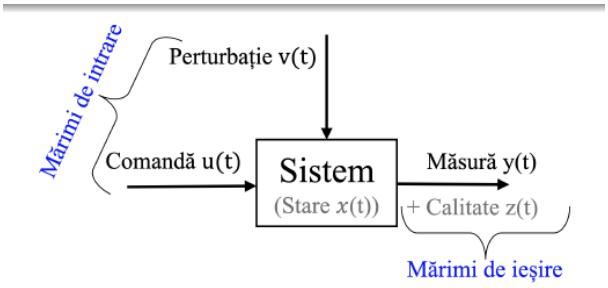

Figura 1.1:

Un model este o descriere a sistemului care îi surprinde comportamentul relevant.

În contextul larg al ingineriei sistemelor, modelele se folosesc pentru următoarele scopuri:

- *Proiectare*: simulare, optimizare, planificare;
- *Estimare*: predicție, soft sensors, filtrare, controlul avansat al proceselor;
- *Controlul*: analiza stabilității, evaluarea performanțelor, proiectarea regulatoarelor;
- *Monitorizare*: controlul calității, detecția defectelor, diagnoza;

Structura algoritmică a unui sistem automat se determină prin modele matematice, care este o procedură analitică de construire a sistemului de conducere automată.

Noțiuni generale despre Sistemele de Reglare Automată (SRA)

Sistemul de reglare automată este un sistem realizat astfel încât între mărimea de ieșire și mărimea de intrare se realizează automat o relație care reflectă legea de conducere a unui proces. Rolul său este de a asigura menținerea automată a unor mărimi tehnologice la o valoare prestabilită.

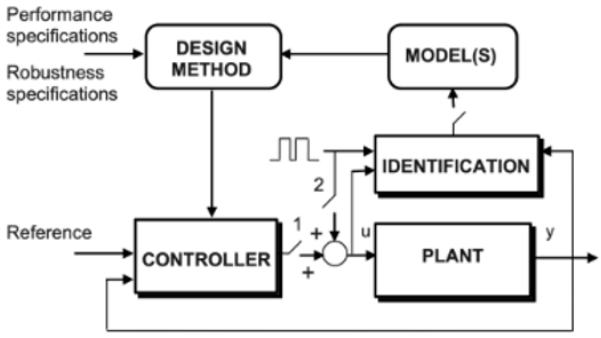

Figura 1.2: Structura de reglare automată

Structura clasică a sistemului de reglare automată cu reacție negativă unitară cu un grad de libertate se dă în fig. 1.3. În această configurație, regulatorul (R) este plasat pe calea directă, fiind conectat în serie cu funcția de transfer PF.

Semnificația variabilelor implicate în procesul de reglare este următoarea:

- $r(t)$ – referința impusă sistemului;
- $y(t)$ – mărimea de ieșire controlată;
- $\varepsilon(t)$ – (eroarea) de reglare;
- $u(t)$ – mărimea de comandă generată de regulator;
- $p(t)$ – perturbațiile externe care acționează asupra procesului.

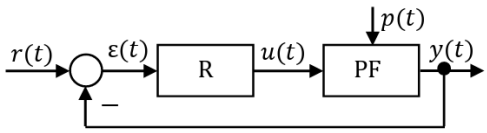

Figura 1.3: Schema funcțională de reglare automată

Clasificarea SRA:

1. După dependența dintre mărimile de ieșire și de intrare:
   - sisteme liniare
   - sisteme neliniare
2. După caracterul prelucrării semnalelor:
   - sisteme cu semnale continue
   - sisteme cu semnale discrete
3. După aspectul variației în timp a mărimii de intrare (și a mărimii de ieșire):
   - sisteme statice
   - sisteme dinamice
4. După numărul de bucle principale de reglare:
   - o singură buclă
   - mai multe bucle
5. După viteza de răspuns a instalației tehnologice:
   - procese rapide
   - procese lente
6. După caracteristicile de construcție ale dispozitivelor de automatizare:
   - sisteme unificate
   - sisteme specializate
7. După agentul purtător de semnal:
   - electrice
   - pneumatice
   - hidraulice
   - mixte

În Figura 2 se prezintă un sistem de achiziție de date care permite interfațarea cu procesul continuu P. Semnalele de intrare și ieșire ale procesului, $u(t)$ și $y(t)$, sunt analogice și în timp continuu, $t \in \mathbb{R}_+$, $u(t), y(t) \in \mathbb{R}$.

Pentru a putea fi stocate și prelucrate cu un calculator numeric, se consideră semnalele eșantionate $u[k]$, $y[k]$, $k = \{1, 2, 3, \ldots, N\}$, cu o perioadă de achiziție $T_e > 0$, fixă.

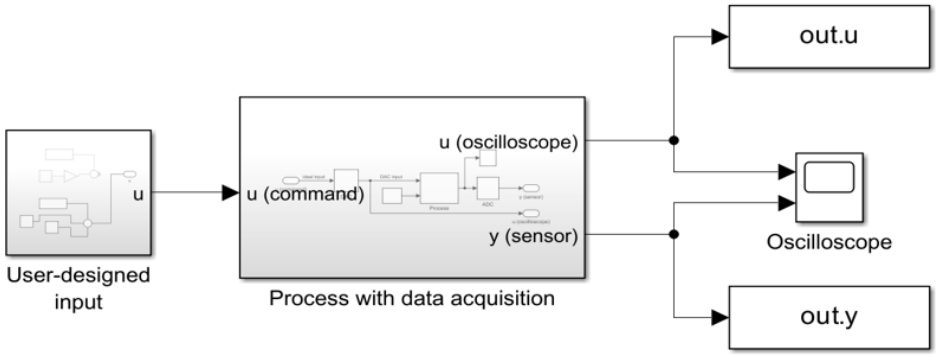

*Figura2

Figura 1.4: Structura sistemelor în mediul Simulink

Pentru a putea fi stocate și prelucrate cu un calculator numeric, se consideră semnalele eșantionate $u[k], y[k]$, $k = \{1, 2, 3, \ldots, N\}$, cu o perioadă de achiziție $T_e > 0$, fixă.

Un aspect crucial în implementarea numerică este alegerea corectă a acestei perioade de eșantionare. Conform **teoremei eșantionării (Shannon-Nyquist)**, pentru a putea reconstitui corect semnalul continuu din eșantioanele sale și pentru a evita fenomenul de *aliere* (aliasing), frecvența de eșantionare $f_e = \frac{1}{T_e}$ trebuie să fie de cel puțin două ori mai mare decât cea mai mare frecvență prezentă în spectrul semnalului util:

$$f_e \geq 2 \cdot f_{\max} \tag{1.1}$$

În practică, în ingineria sistemelor, pentru a asigura o performanță bună a reglării și o reconstrucție fidelă a semnalului, se alege adesea o frecvență de eșantionare mult mai mare ($f_e \approx 10 \ldots 20 \cdot f_{\max}$).

Interfațarea dintre calculatorul numeric (care lucrează cu secvențe discrete de numere) și procesul fizic (care evoluează în timp continuu) se realizează prin intermediul convertoarelor, elemente esențiale în schema de conducere numerică:

- **Convertorul Analog-Numeric (CAN):** Transformă semnalul de ieșire al procesului $y(t)$ într-o secvență de valori numerice $y[k]$ pe care algoritmul de reglare le poate procesa.
- **Convertorul Numeric-Analog (CNA):** Transformă comanda calculată de algoritmul numeric $u[k]$ într-un semnal continuu (de obicei prin menținere de ordin zero - ZOH), necesar pentru a acționa asupra elementului de execuție.

Capitolul 2. Obiectivele lucrării

Prezenta lucrare sintetizează activitatea de analiză și modelare a sistemelor dinamice, fiind structurată în două etape majore care corespund progresiei logice de la analiza fizică la modelarea abstractă. Studiul se desfășoară comparativ pe două procese cu comportament dual:

- **Sistemul Hidraulic:** Proces lent, aperiodic, guvernat de legi de curgere și acumulare de masă.
- **Convertorul DC-DC Boost:** Proces rapid, cu potențial oscilant, guvernat de legi de comutație electromagnetică.

Obiectivele sunt împărțite conform celor două metodologii studiate:

2.1. Partea I: Metode Neparametrice (Proiectele 1 și 2)

Această primă etapă vizează extragerea caracteristicilor dinamice direct din răspunsul experimental al sistemelor, fără a presupune a priori o structură matematică fixă. Nu se utilizează algoritmi de optimizare complexă, ci analiza directă a semnalelor.

Obiective specifice:

- **Analiza Răspunsului Tranzitoriu (Step Response):** Determinarea parametrilor de timp prin aplicarea unui semnal treaptă simplu:
  - Identificarea constantei de timp dominante (T) și a timpului de stabilire (t_s).
  - Pentru sistemul hidraulic, se urmărește confirmarea caracterului aperiodic

2.2. Partea II: Metode Parametrice (Proiectele 3 și 4)

A doua parte a lucrării face trecerea către modelarea avansată , unde scopul este obținerea unei funcții de transfer sau a unui set de ecuații de stare care să descrie matematic procesul.

Obiective specifice:

- **Proiectarea Experimentului Avansat (SPAB):** Deoarece semnalul treaptă nu oferă suficientă excitație în frecvență, obiectivul principal este calibrarea și generarea unui Semnal Pseudo-Aleator Binar.
- **Identificarea Familiei de Modele:** Estimarea parametrilor pentru structuri probabilistice complexe:
  - *ARX/ARMAX:* Pentru sisteme unde zgomotul este modelat unitar cu dinamica.
  - *Output Error (OE) și Box-Jenkins (BJ):* Pentru separarea completă a modelului procesului de modelul perturbatiilor.
- **Identificarea în Spațiul Stărilor (State-Space):** Utilizarea metodelor de subspațiu (ssesd) pentru a determina ordinul optim al sistemului
- **Validarea și Compararea Modelelor:** Selectarea modelului optim pe baza criteriului de suprapunere (FIT $> 75\%$) și a analizei reziduurilor .

Capitolul 3. Fundamente teoretice: Metode Neparametrice

3.1. Considerații generale

Acest capitol stabilește cadrul formal și fundamentele matematice necesare pentru metodele de identificare utilizate în lucrare. Deși aplicația practică vizează modelarea unui sistem specific de ordinul II, este esențială o înțelegere profundă a principiilor teoretice generale, având ca punct de plecare regresia liniară.

Obiectivul central al acestui capitol este de a ilustra modul în care algoritmii de identificare pot face tranziția de la date experimentale brute (identificare neparametrică, bazată pe curbe de răspuns) la un model matematic riguros. Concret, se urmărește demonstrarea capacității regresiei liniare de a extrage parametrii structurali ai unui sistem (K, T_1, T_2) analizând exclusiv răspunsul acestuia la un semnal treaptă.

3.2. Metoda regresiei liniare

Regresia liniară este cel mai simplu tip de model parametric, utilizată pentru a identifica comportamentul unei variabile dependente, notată cu $y(t)$, pornind de la un set de date cunoscut.

Obiectiv: găsirea unor valori θ astfel încât variabila dependentă aproximată:
$\hat{y}(t) = \varphi^\top(t) \cdot \hat{\theta}$ – să fie cât mai aproape posibil de $y(t)$.

Considerând un set de N măsurători experimentale, modelul liniar general la un moment de timp t se definește prin relația:

$$y(t) = \varphi^T(t) \cdot \theta + e(t) = \sum_{i=1}^{n} \varphi_i(t)\theta_i + e(t) \tag{3.1}$$

Unde:

- $y(t)$ reprezintă ieșirea măsurată a sistemului;
- $\varphi(t) \in \mathbb{R}^n$ este vectorul regresorilor (mărimile cunoscute sau măsurate);
- $\theta \in \mathbb{R}^n$ este vectorul parametrilor necunoscuți ce trebuie identificați;
- $e(t)$ reprezintă eroarea de modelare (zgomotul sau neconcordanțele dintre model și realitate).

Prin extinderea acestei relații pentru întregul set de date achiziționate (pentru $t = 1, \ldots, N$), și considerând că numărul de măsurători este mai mare decât numărul parametrilor ($N > n$), obținem forma matriceală a sistemului de ecuații:

$$Y = \Phi\theta + E \tag{3.2}$$

În această scriere compactă:

- $Y \in \mathbb{R}^N$ este vectorul coloană al tuturor măsurătorilor;
- $\Phi \in \mathbb{R}^{N \times n}$ este matricea de regresie (fiecare linie corespunde unui moment de timp);
- $E \in \mathbb{R}^N$ este vectorul erorilor.

În proiectul nostru este necesar să folosim regresia pe date logaritmate.

În contextul identificării sistemelor, această metodă este fundamentală deoarece permite estimarea parametrilor unui model dinamic prin minimizarea sumei pătratelor reziduurilor (diferențelor dintre datele măsurate și cele simulate), proces cunoscut sub numele de Metoda Celor Mai Mici Pătrate.

3.2.1. Metoda Celor Mai Mici Pătrate (MCMMP)

Pentru determinarea vectorului optim de parametri $\hat{\theta}$, se utilizează **Metoda Celor Mai Mici Pătrate (MCMMP)**. Această metodă caută acea valoare a parametrilor care minimizează discrepanța dintre datele reale și predicția modelului. Matematic, acest lucru echivalează cu minimizarea unei funcții de cost pătratice, $V(\theta)$:

$$\hat{\theta} = \arg\min_{\theta} V(\theta) = \arg\min_{\theta} \left(\frac{1}{2} \sum_{t=1}^{N} \epsilon^2(t) \right) = \arg\min_{\theta} \left(\frac{1}{2} \|Y - \Phi\theta\|_2^2 \right) \tag{3.3}$$

Rezolvarea analitică a acestei probleme de optimizare (prin anularea derivatei funcției de cost în raport cu θ) conduce la ecuația :

$$\hat{\theta} = (\Phi^T \Phi)^{-1} \Phi^T Y \tag{3.4}$$

Această soluție permite calculul direct al parametrilor estimați $\hat{\theta}$ folosind exclusiv datele experimentale disponibile în vectorul Y și matricea Φ.

3.3. Liniarizarea modelului prin metoda logaritmării succesive

Aceasta reprezintă o metodă de identificare a sistemelor ce conțin una sau mai multe constante de timp. Metoda logaritmărilor succesive are ca fundament regresia liniară.

3.3.1. Modelul procesului fizic

În general, procesele fizice care pot fi modelate printr-un sistem LTI de ordinul II cu poli reali au următoarea funcție de transfer :

$$H(s) = \frac{K}{(T_1 s + 1)(T_2 s + 1)}, \quad T_1 > T_2 \tag{3.5}$$

Parametrii care trebuie identificați sunt: factorul de proporționalitate K și cele două constante de timp: $T_1[s]$ și $T_2[s]$.

Răspunsul indicial al sistemului descris de ecuația 3.5 este dat de relația:

$$y(t) = K \cdot \left(1 - \frac{T_1}{T_1 - T_2} e^{-\frac{t}{T_1}} + \frac{T_2}{T_1 - T_2} e^{-\frac{t}{T_2}} \right), \quad t \geq 0 \tag{3.6}$$

3.3.2. Identificarea constantei de timp dominante (T_1)

Pentru a identifica valoarea constantei de timp T_1, se logaritmează relația 3.6 și se obține:

$$\ln(y(t_k) - K) = \ln \frac{K}{T_1 - T_2} - \frac{1}{T_1} t_k + \ln \left(-T_1 + T_2 e^{-t_k \frac{T_1 - T_2}{T_1 T_2}} \right) \tag{3.7}$$

unde t_k sunt eșantioane de timp. Similar cu cazul sistemelor de ordinul I, aceste eșantioane se aleg de la momentul declanșării treptei până ce al treilea termen are o valoare ce influențează posibilitatea de utilizare a regresiei liniare. Astfel, relația devine o problemă de regresie liniară și obținem :

$$T_1 = \frac{-1}{\alpha_1} \tag{3.8}$$

unde α_1 este parametrul determinat conform formulei regresiei.

În practică, formula trebuie adaptată pentru a evita logaritmarea unui număr negativ și pentru a surprinde condițiile inițiale nenule și semnalele de intrare neideale. Acest lucru se face prin utilizarea modulului diferenței față de valoarea staționară: $\ln(|y(t_k) - \overline{y}_{st}|)$.

3.3.3. Identificarea constantei de timp secundare (T_2)

Similar, pentru a identifica a doua constantă de timp (T_2), se elimină din răspunsul indicial modul corespunzător constantei de timp T_1 și se obține o problemă clasică de regresie liniară pe ultima parte a răspunsului (de unde a fost finalizată alegerea eșantioanelor pentru identificarea primei constante de timp până la intrarea în regim staționar) :

$$T_2 = -\frac{1}{\alpha_2} \tag{3.9}$$

unde α_2 este parametrul determinat conform formulei regresiei [**?**].

3.4. Identificarea parametrilor pe baza pulsației la faza de $-\frac{\pi}{2}$

Identificarea sistemelor de ordinul II se bazează pe alegerea structurii modelului și exploatarea punctului în care faza sistemului este de $-\frac{\pi}{2}$ ($-90°$).

Modelul propus

Structura adecvată pentru modelarea sistemului este definită astfel:

$$H(s) = \frac{K \cdot \omega_n^2}{s^2 + 2\zeta\omega_n s + \omega_n^2} \tag{3.10}$$

unde:

- K este factorul de proporționalitate;
- ζ este factorul de amortizare, $\zeta \in (0, \infty)$;
- ω_n este pulsația naturală de oscilație.

Problema de identificare constă în determinarea valorilor lui K, ζ și ω_n.

Procedura de identificare

Identificarea parametrilor se realizează în următorii pași:

1. Determinarea factorului de proporționalitate (K)

Acesta se deduce din capătul de frecvență joasă (regimul staționar):

$$K = H(0) \tag{3.11}$$

2. Identificarea pulsației naturale (ω_n)

Din datele experimentale se caută pulsația la care faza este $-\frac{\pi}{2}$. În acest punct, partea reală a răspunsului în frecvență devine nulă ($Re\{H(j\omega)\} = 0$):

$$\omega_n = \omega \quad (\text{la faza de } -90^\circ) \tag{3.12}$$

3. Determinarea factorului de amortizare (ζ)

Cunoscând partea imaginară a punctului experimental la frecvența ω_n (notată cu $Y = Im\{H(j\omega_n)\}$), se utilizează relația:

$$Im\{H(j\omega_n)\} = \frac{-K}{2\zeta} = Y \tag{3.13}$$

De unde rezultă expresia de calcul pentru factorul de amortizare:

$$\zeta = -\frac{K}{2Y} \tag{3.14}$$

Determinarea constantelor de timp (pentru poli reali)

În cazul în care $\zeta > 1$ (așa cum rezultă în cazul sistemelor supraamortizate, de exemplu $\zeta \approx 2.5$ în exemplul din curs), sistemul are o pereche de poli reali.

Modelul identificat revine la forma cu constante de timp prin descompunerea numitorului:

$$s^2 + 2\zeta\omega_n s + \omega_n^2 = (T_1 s + 1)(T_2 s + 1) \cdot \omega_n^2 \tag{3.15}$$

3.5. Semnale de test Neparametrice

Semnalul de tip treaptă

Semnalul de tip treaptă, în cazul ideal, reprezintă o trecere imediată de la 0 la 1 la momentul $t = 0$.

Semnalul de tip treaptă în cazul general se poate defini ca o trecere de la un moment de timp t_0 de la o valoare inițială u_0 la o valoare finală u_{st}:

$$\overline{1}(t) = \begin{cases} u_{st} & , \quad t > t_0 \\ u_0 & , \quad t \leq t_0 \end{cases}.$$

Semnal de tip chirp

Este un semnal sinusoidal a cărui frecvență variază continuu în timp între o valoare minimă (f_{min}) și una maximă (f_{max}), pe parcursul unei durate determinate (T_{sweep}).

Matematic, acesta se exprimă ca:

$$u(t) = A\sin(\phi(t))$$

Semnalul este bogat în armonice și permite excitarea treptată a sistemului într-o gamă largă de frecvențe. El este foarte util pentru determinarea răspunsului în frecvență al sistemului.

Capitolul 4. Proiect 1: Identificarea sistemelor de ordin II cu poli reali

Studiu de caz: Procesul Hidraulic

4.1. Scopul acestui proiect

Proiectul propune identificarea modelelor matematice ale sistemelor de ordinul II utilizând metoda regresiei liniare. Pentru efectuarea experimentului, semnalul de intrare utilizat va fi de tip treaptă.

4.2. Descrierea procesului fizic

Experimentul vizează achiziția de date pentru un sistem dinamic cu regim aperiodic amortizat, ilustrat în Figura 4.1. Se prezintă un proces de reglare de nivel în cazul a două rezervoare deschise conectate în serie. Reglarea nivelului se realizează în cel de-al doilea rezervor, mărimea de execuție fiind debitul de intrare în primul rezervor.

Variabilele sistemului sunt definite astfel:

- **Semnalul de intrare,** $u(t)$: reprezintă debitul de intrare în primul rezervor $[m^3/s]$;
- **Semnalele de stare,** $x_1(t)$ **și** $x_2(t)$: reprezintă nivelul de lichid în primul, respectiv al doilea rezervor $[m]$;
- **Semnalul de ieșire,** $y(t)$: reprezintă măsura scalată a nivelului lichidului din al doilea rezervor $[m]$.

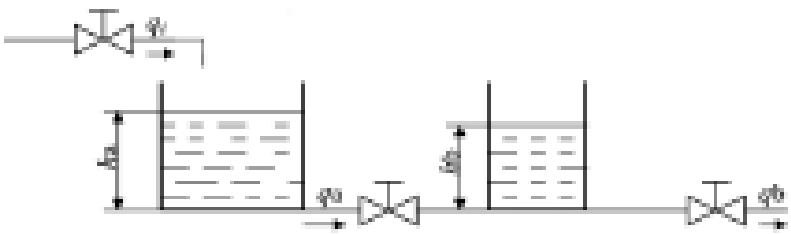

Figura 4.1: Schema de reglare a nivelului pentru procesul cu două rezervoare în serie

4.3. Modelul propus și pașii experimentali

Se propune modelarea sistemului utilizând următoarea structură a funcției de transfer:

$$H(s) = \frac{K}{(T_1 s + 1)(T_2 s + 1)}, \quad K, T_1, T_2 > 0, \quad T_1 \gg T_2. \tag{4.1}$$

Factorul de proporționalitate K este dat de amplificarea sistemului în regim staționar.

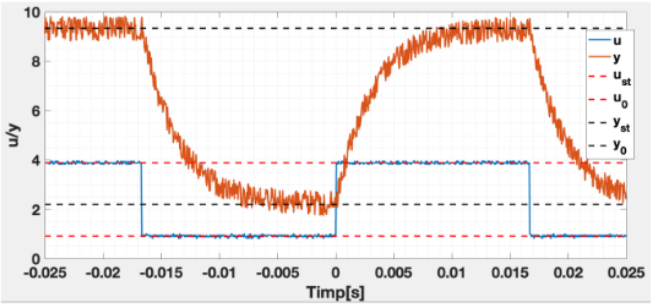

Figura 4.2: Identificarea grafică a nivelelor staționare pentru calculul lui K

Unde:

- y_{st}: valoarea medie a ieșirii la final (regim stabilizat);
- u_{st}: valoarea medie a intrării (amplitudinea treptei aplicate).

4.3.1. Configurarea simulării

Pentru realizarea proiectului de identificare a fost utilizat cadrul de simulare (framework-ul) oferit în materialele de laborator. Scriptul MATLAB rulat preliminar procesului de identificare propriu-zis este structurat pe mai multe secțiuni:

- **Secțiunea** `Process Data`: Calculează constantele fizice ale rezervoarelor (c_1, c_2, a_1, a_2) și setează condițiile inițiale ($x0_slx$).
- **Secțiunea** `Experiment Setup`: Asigură realismul simulării și configurează parametrii de achiziție a datelor. Aceasta include:
  - Ts: Pasul de eșantionare (frecvența cu care se efectuează măsurătorile);
  - T_{fin}: Durata totală a simulării;
  - $u_{min}, u_{max}, y_{min}, y_{max}$: Limitele fizice de saturație pentru intrare (robinet) și ieșire (rezervor);
  - $Zgomot$: Adăugarea perturbațiilor stocastice pentru a simula condițiile reale.
- **Secțiunea** `Input Setup`: Definește parametrii semnalului treaptă aplicat: valoarea de start (u_0), valoarea finală (u_{st}) și momentul declanșării treptei (t_1).
- **Secțiunea** `Data Acquisition`: Realizează rularea efectivă a simulării Simulink și extragerea datelor.

Odată definită configurația experimentului și executată simularea, se obțin vectorii de date experimentale: timpul (t), intrarea treaptă aplicată (u) și răspunsul sistemului (y). Aceste date brute constituie intrarea pentru algoritmul de identificare.

4.4. Identificarea Experimentală a Parametrilor

4.4.1. Determinarea factorului de proporționalitate (K)

Factorul de proporționalitate este definit ca raportul dintre variația ieșirii și variația intrării în regim staționar:

$$K = \frac{y_{st} - y_0}{u_{st} - u_0}. \tag{4.2}$$

Pentru calculul exact, s-au selectat ferestre de mediere a datelor, delimitate de indicii i_1, i_2, i_3, i_4, conform figurii de mai jos:

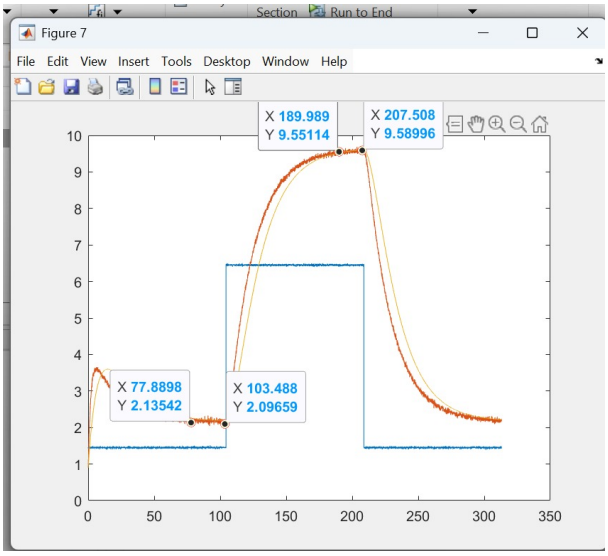

Figura 4.3: Selecția zonelor de staționaritate pentru calculul mediilor

Selecția indicilor s-a făcut după cum urmează:

- intervalul $[i_1, i_2]$ a fost ales înainte de momentul $t = 0$ (declanșarea treptei), pentru a determina condițiile inițiale y_0, u_0.
- intervalul $[i_3, i_4]$ a fost ales mult după terminarea regimului tranzitoriu (timpul de stabilizare), pentru a determina valorile finale y_{st}, u_{st}.

```
%Indecsii la declasarea treptei(t=0)
i1=4976;
i2=6611;
%Indecsi la stabilizare
i3=12136;
i4=13255;

%Calcularea valorilor medii
y_st=mean(y(i3:i4));
y0=mean(y(i1:i2));

u_st=mean(u(i3:i4));
u0=mean(u(i1:i2));

k=(y_st-y0)/(u_st-u0)+0.02
```

Figura 4.4: Secvență de cod pentru calculul mediei și a factorului K

Valorile extrase au fost prelucrate folosind funcția `mean` din MATLAB pentru a minimiza efectul zgomotului de măsură.

4.4.2. Calcularea constantei de timp dominante (T_1)

Identificarea lui T_1 se bazează pe liniarizarea răspunsului logaritmat. Punctele i_5 și i_6 au fost alese pentru a delimita zona liniară a logaritmului răspunsului tranzitoriu:

- Punctul i_5 (t_1): Fixat imediat după zona inițială, unde curba începe să urce semnificativ.
- Punctul i_6 (t_2): Ales înainte ca sistemul să intre în zona de saturație a regimului staționar.

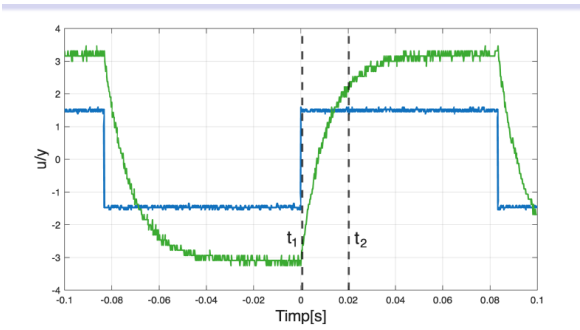

Figura 4.5: *
Selecția ferestrei de regresie pe datele experimentale

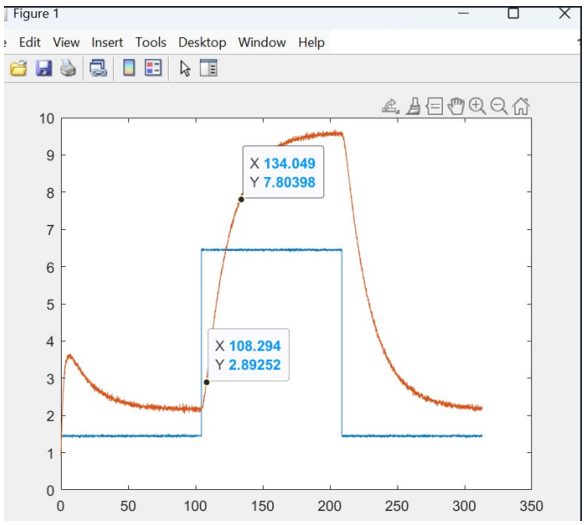

Figura 4.6: *
Poziționarea indicilor i_5, i_6

Această fereastră $[i_5, i_6]$ corespunde zonei de inflexiune, unde viteza de acumulare în rezervor este maximă, permițând o estimare precisă a pantei.

```
t_reg=t(i5:i6);
y_reg=log(y_st-y(i5:i6));
figure
plot(t_reg,y_reg)

Areg=[sum(t_reg.^2),sum(t_reg);
        sum(t_reg),length(t_reg)];
breg=[sum(y_reg.*t_reg);sum(y_reg)];

theta=inv(Areg)*breg
T1=-1/theta(1)
```

Figura 4.7: Codul MATLAB pentru regresia liniară

Elementele algoritmului de regresie sunt:

- `t_reg`, `y_reg`: Vectorii de date limitați la intervalul de interes.
- `Areg`: Matricea sistemului (sumele eșantioanelor de timp t și t^2).
- `breg`: Vectorul termenilor liberi (corelația timp-ieșire logaritmată).
- `theta`: Soluția sistemului de regresie.
- `T1 = -1/theta(1)`: Formula finală de extracție a constantei de timp.

4.4.3. Determinarea constantei de timp secundare (T_2)

Constanta T_2 se estimează pe baza punctului de inflexiune al răspunsului indicial $y(t)$. Indicii i_7 și i_8 sunt utilizați pentru a calcula timpul scurs de la aplicarea treptei până la punctul de inflexiune: $T_i = t(i_8) - t(i_7)$.

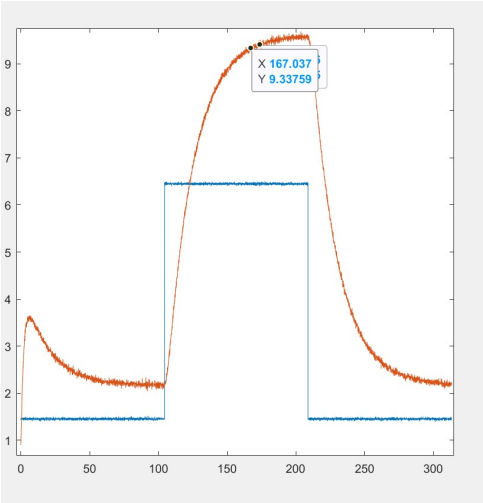

Figura 4.8: Identificarea vizuală a timpului de inflexiune T_i

Valoarea lui T_2 se obține prin rezolvarea numerică a ecuației transcendente derivate din modelul matematic:

$$T_1 T_2 \ln(T_2) - T_2[T_i + T_1 \ln(T_1)] + T_1 T_i = 0 \tag{4.3}$$

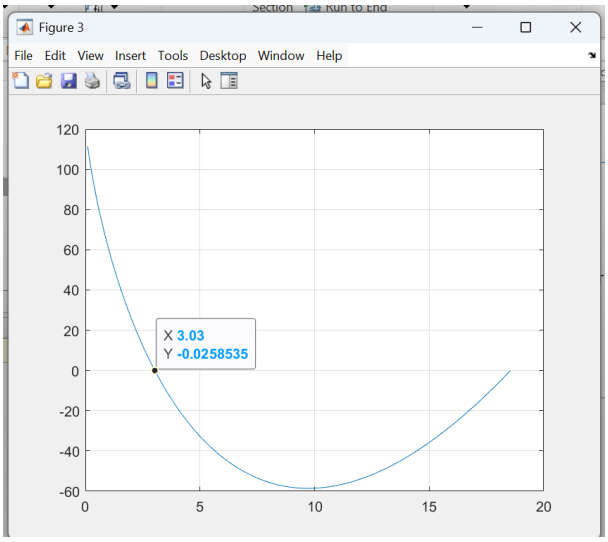

Figura 4.9: Punctul T_2 pe grafic

4.5. Validarea Modelului și Analiza Performanței

Pe baza parametrilor identificați (K, T_1, T_2), a fost construit modelul în spațiul stărilor:

```
A=[0,1;-1/T1/T2,-(1/T1+1/T2)];
B=[0;k/T1/T2];
C=[1,0];
D=0;
sys=ss(A,B,C,D);
ysim2=lsim(sys,u,t,[y(1),1.13]);
```

Figura 4.10: Modelul în spațiul stărilor generat în MATLAB

Răspunsul acestui model la același semnal de intrare $u(t)$ a fost simulat și comparat cu datele reale $y(t)$.

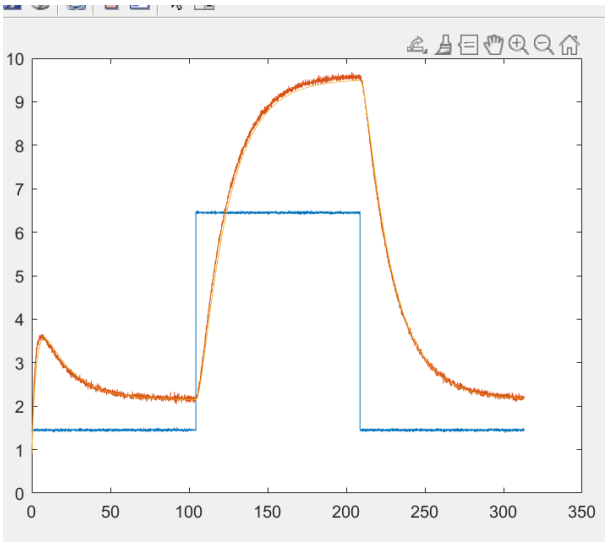

Figura 4.11: Suprapunerea răspunsului simulat (galben) peste datele reale (roșu)

Pentru cuantificarea performanței modelului, s-a calculat Eroarea Medie Pătratică Normalizată (EMPN):

$$\epsilon_{MPN} = \frac{\|y - y_{sim}\|}{\|y - \bar{y}\|} \times 100[\%] \tag{4.4}$$

Valoarea obținută a fost $\epsilon_{MPN} = 0.0355$. Exprimată procentual, aceasta reprezintă o eroare de **3.55%**, ceea ce validează modelul, încadrându-se sub limita de 10% impusă de cerințele proiectului. EOF

Capitolul 5. Proiect 2: Identificarea sistemelor de ordin II folosind semnale de tip Chirp

5.1. Scopul acestui proiect

Proiectul de față propune identificarea modelelor matematice ale sistemelor de ordinul II utilizând estimarea răspunsului în frecvență. Se vor utiliza semnale de intrare de tip *Chirp* (sinusoidal cu frecvență variabilă) pentru efectuarea experimentelor.

5.2. Descrierea procesului fizic

Se păstrează sistemul cu două rezervoare înseriate descris în proiectul anterior.

5.3. Modelul propus și pașii experimentului

Structura modelului matematic depinde de natura polilor sistemului. În cazul de față, avem poli reali (sistem supraamortizat), descris de funcția de transfer:

$$H(s) = \frac{K}{(T_1 s + 1)(T_2 s + 1)}, \quad T_1 \gg T_2 > 0 \tag{5.1}$$

Se va genera o secvență de intrare de tip Chirp în jurul punctului de funcționare precizat (variabila *u_op_region* preluată din proiectul anterior). Calibrarea semnalului de intrare trebuie făcută în baza principiilor teoretice.

Pentru realizarea proiectului de identificare a fost utilizat cadrul de simulare oferit în cadrul laboratorului. Această secțiune de cod a fost rulată preliminar procesului de identificare propriu-zis, fiind alcătuită din următoarele module:

- **Secțiunea** `Process Data`: Această secțiune calculează coeficienții fizici interni ai rezervoarelor (c_1, c_2, a_1, a_2) și setează condițiile inițiale $(x0_slx)$, identic cu proiectul anterior.
- **Secțiunea** `Experiment Setup`: Configurează parametrii simulării și ai zgomotului. Se păstrează T_s (timpul de eșantionare), T_{fin} (durata simulării), precum și limitele de saturație (u_{min}, u_{max}).
- **Secțiunea** `Input Setup`: Spre deosebire de proiectul anterior, aici se definesc parametrii semnalului de intrare de tip **Chirp**:
  - **Ain**: Amplitudinea semnalului sinusoidal;
  - **fmin, fmax**: Banda de frecvență (minimă și maximă).
- **Secțiunea** `Data acquisition`: Realizează rularea simulării apelând fișierul Simulink și extrage vectorii de timp (t), intrare (u) și ieșire (y).

5.4. Identificarea experimentală a parametrilor

Identificarea nu se mai bazează pe regresie temporală, ci pe analiza punctelor cheie din caracteristica de frecvență.

5.4.1. Identificarea parametrilor sistemelor de ordin II cu poli reali

Conform metodologiei prezentate, identificarea sistemului se bazează pe analiza răspunsului în frecvență în zona de cuadratură. Modelul propus pentru acest proces este definit prin funcția de transfer:

$$H(s) = \frac{K \cdot \omega_n^2}{s^2 + 2\zeta\omega_n s + \omega_n^2} = \frac{K}{(T_1 s + 1)(T_2 s + 1)} \tag{5.2}$$

5.4.2. Determinarea factorului de proporționalitate K

Factorul de proporționalitate K se poate deduce la capătul de frecvență joasă (CFJ) utilizând una dintre următoarele metode:

- **Metoda amplitudinii (analogia cu diagrama Bode):** Raportul amplitudinilor semnalelor de ieșire și intrare:

$$K \approx \frac{A_y^{CFJ}}{A_u^{CFJ}} \tag{5.3}$$

- **Metoda valorilor medii (analogia cu răspunsul la impuls):** Raportul valorilor medii în regim staționar:

$$K \approx \frac{\bar{y}_{st}}{\bar{u}_{st}} \tag{5.4}$$

```
yst=(2.34+1.94)/2
ust=1.45 %l am determinat cu u_op_region
K=yst/ust+0.02;
```

Figura 5.1: Determinarea factorului K din răspunsul la frecvență joasă

Pentru calcularea lui y_{st} s-au identificat vizual valorile de maxim și minim local într-o fereastră de timp în care semnalul este stabil.

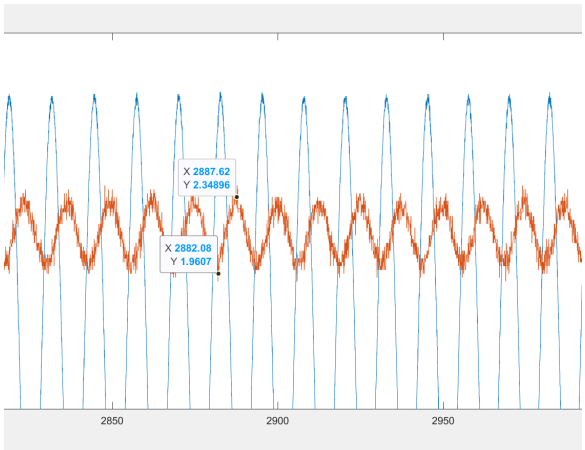

Figura 5.2: Evidențierea indecșilor pentru alegerea punctelor pentru y_{st}

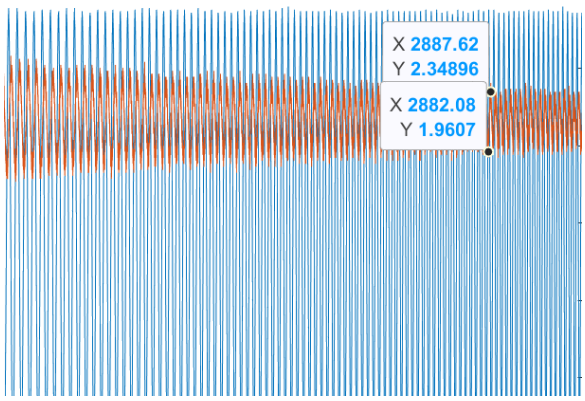

Figura 5.3: Vizualizarea ferestrei de selecție

Valoarea parametrului `u_op_region` a fost determinată analitic, utilizând relația de calcul impusă în scriptul de configurare al laboratorului. Aceasta depinde de parametrii individuali $m = 5$ și $n = 2$:

$$u_{op_region} = \frac{m/2 + n/5}{2} = \frac{2.5 + 0.4}{2} = 1.45 \text{ [V]} \tag{5.5}$$

5.4.3. Determinarea parametrilor dinamici (ζ, ω_n)

Experimentul se bazează pe identificarea pulsației care aduce sistemul la faza de $-\frac{\pi}{2}$ (sau $-90°$). În această regiune, semnalele de intrare și ieșire sunt **în cuadratură**.

Relațiile teoretice utilizate sunt:

- **Pulsația naturală (ω_n):** Se identifică pulsația ω pentru care partea reală a răspunsului în frecvență este nulă, $Re\{H(j\omega)\} = 0$.

$$\omega_n = \omega \quad \text{(la faza de } -90°) \tag{5.6}$$

- **Factorul de amortizare (ζ):** Se utilizează valoarea părții imaginare $Y = Im\{H(j\omega_n)\}$ citită din grafic:

$$\zeta = -\frac{K}{2Y} \tag{5.7}$$

În urma acestor calcule, rezultă $\zeta > 1$ și $\omega_n > 0$, condiții ce permit reconstruirea celor două constante de timp dominante și nedominate, T_1 și T_2.

Procedura experimentală

1. **Identificarea pulsației naturale (ω_n):** Deoarece frecvența semnalului de intrare este variabilă, s-au analizat patru puncte succesive de pe grafic ($w_1 \dots w_4$).

```
w2=pi/(1045.68-1028.99)
deltaT2=1037.54-1028.99
phi2=-rad2deg(w2*deltaT2) %valoarea cea mai buna
```

Figura 5.4: Secvență de cod pentru calculul pulsațiilor

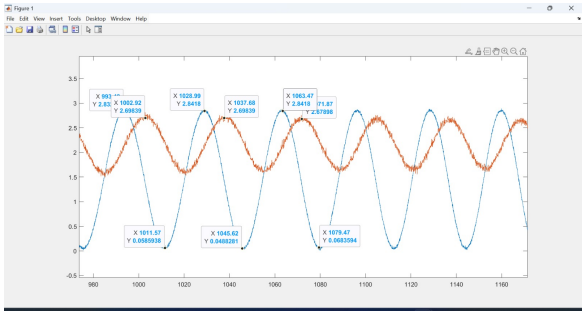

Figura 5.5: Identificarea punctelor pe grafic și defazajul rezultat

Pașii de calcul pentru fiecare punct analizat:

- **Calculul pulsației (ω):** S-a determinat semi-perioada semnalului, măsurată ca distanța temporală dintre un maxim local și minimul imediat următor al semnalului de intrare.
- **Determinarea întârzierii (ΔT):** S-a calculat diferența de timp dintre vârful semnalului de răspuns (y) și vârful semnalului de intrare (u). Valoarea rezultată reprezintă întârzierea introdusă de sistem la pulsația respectivă.
- **Calculul defazajului (ϕ):** Reprezintă schimbarea de fază calculată în grade. Acesta este criteriul de validare al experimentului.

- **Selecția finală:** S-a validat punctul w_2 drept pulsație naturală ω_n, deoarece defazajul rezultat în acest punct a fost cel mai apropiat de criteriul teoretic de $-90°$.

2. **Determinarea amplitudinilor:** În punctul de rezonanță identificat (w_2), s-au extras amplitudinile semnalelor:
   - Amplitudinea ieșirii (A_y) a fost calculată prin metoda vârf-la-vârf: $A_y = (y_{max} - y_{min})/2$.

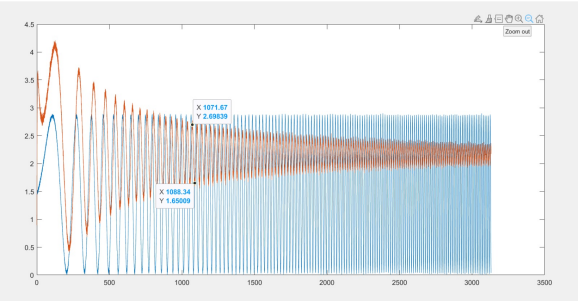

Figura 5.6: Calculul amplitudinii A_y

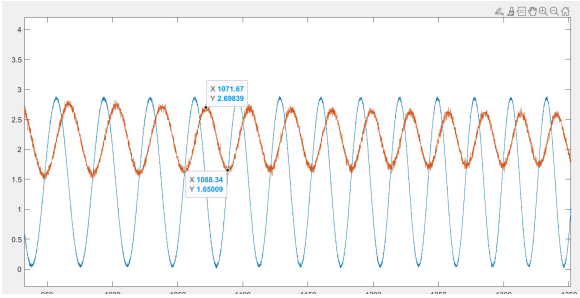

Figura 5.7: Punctele selectate pentru amplitudine

   - Amplitudinea intrării (A_u) este constantă, conform configurării experimentului ($A_u = 1.4$).

3. **Calculul factorului de amortizare (ζ):** Utilizând proprietatea sistemului la rezonanță (partea reală nulă), factorul ζ a fost derivat din componenta imaginară a răspunsului în frecvență. S-a obținut valoarea:

$$\zeta = 2.01$$

```
Ay=(2.69-1.65)/2
Au=1.4
Im=-Ay/Au
wn=w2
zeta=-K/2/Im
```

Figura 5.8: Calculul final al factorului de amortizare

5.5. Validarea modelului și analiza performanței

Validarea modelului s-a realizat prin compararea ieșirii reale a sistemului cu ieșirea simulată a modelului identificat, având la intrare același semnal de tip Chirp.

Deoarece sistemul este supraamortizat ($\zeta > 1$), funcția de transfer poate fi descompusă într-o formă cu poli reali distincți, evidențiind cele două constante de timp ale procesului. S-a utilizat comanda `zpk(H)` pentru a extrage polii sistemului (p_1, p_2), iar constantele de timp au fost calculate ca inversul modulelor acestora:

$$T_1 = \frac{1}{|p_1|} = \frac{1}{0.05} = 20 \text{ s}, \quad T_2 = \frac{1}{|p_2|} = \frac{1}{0.7} \approx 1.42 \text{ s} \tag{5.8}$$

Folosind parametrii determinați, am construit modelul în spațiul stărilor:

```
A=[0,1;-1/T1/T2,-(1/T1+1/T2)];
B=[0;K/T1/T2];
C=[1,0];
D=0;
sys=ss(A,B,C,D);
ysim2=lsim(sys,u,t,[y(1),2.2]);
```

Figura 5.9: Modelul în spațiul stărilor

Pentru evaluarea performanței, s-a calculat Eroarea Medie Pătratică Normalizată (EMPN):

$$\epsilon_{MPN} = \frac{\|y - y_{sim}\|}{\|y - \bar{y}\|} \times 100[\%] \tag{5.9}$$

Valoarea obținută a fost $\epsilon_{MPN} = 0.0946$. Exprimată procentual, aceasta reprezintă o eroare de **9.46%**, validând modelul obținut.

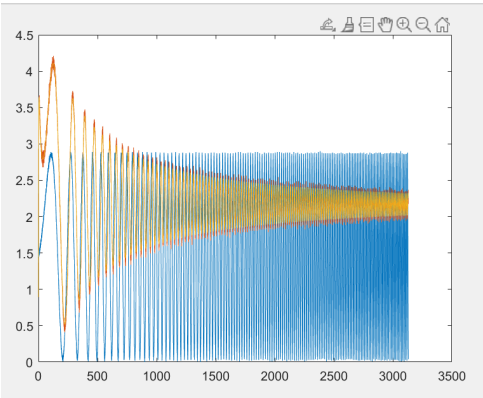

Figura 5.10: Compararea răspunsului real cu cel simulat pentru semnalul Chirp

Capitolul 6. Fundamente Teoretice: Metode Parametrice

Această secțiune a proiectului se concentrează pe identificarea sistemelor prin intermediul modelelor parametrice. În contrast cu abordările neparametrice, care furnizează o descriere preponderent grafică a comportamentului sistemului (ex. răspunsul la impuls), metodele parametrice vizează determinarea analitică a coeficienților unei structuri matematice prestabilite, având ca obiectiv central minimizarea erorii de predicție.

6.1. Semnalul Pseudo-Aleator Binar (SPAB)

6.1.1. Definiție și Caracteristici

Semnalul SPAB este un semnal determinist, periodic, care comută între două niveluri de amplitudine ($+a$ și $-a$ sau a și 0), având proprietăți statistice similare cu cele ale zgomotului alb.

Principalul motiv al utilizării acestui tip de semnal în identificarea sistemelor este necesitatea folosirii unor semnale "bogate în frecvență", care să asigure condiția de excitație persistentă a procesului.

6.1.2. Generarea Semnalului

Semnalele SPAB se obțin algoritmic folosind registre de deplasare cu reacție (Linear Feedback Shift Registers).

6.1.3. Proprietăți

Principalele caracteristici care recomandă utilizarea SPAB sunt:

- **Spectru larg de frecvențe:** conține componente armonice distribuite aproape uniform până la o anumită frecvență maximă.
- **Perioadă lungă:** pentru un registru de deplasare cu N celule, secvența completă are lungimea $2^N - 1$.
- **Determinism:** poate fi generat oricând identic, asigurând comparabilitate între experimente.
- **Amplitudine constantă:** semnalul are o energie uniform distribuită în timp, evitând saturația sistemelor testate.

6.1.4. Principii de Calibrare Teoretică

Parametrii unui SPAB (N, p, T_s) se aleg pe baza dinamicii sistemului, respectând următoarele criterii:

1. **Banda de frecvență:** Cel mai scurt impuls (dat de $p \cdot T_s$) trebuie să fie suficient de mic pentru a excita cele mai rapide constante de timp ale sistemului.
2. **Lungimea secvenței:** Cel mai lung impuls posibil ($N \cdot p \cdot T_s$) trebuie să fie comparabil cu timpul de ridicare al sistemului (t_r).
3. **Perioada totală:** Durata întregii secvențe ($L \cdot p \cdot T_s$) trebuie să fie mai mare decât timpul de stabilizare al sistemului (t_s), pentru a surprinde dinamica lentă.

6.2. Structuri de Modele Parametrice

Modelul general proces + perturbație al unui sistem polinomial discret este descris de relația generală în operatorul de întârziere z^{-1}, unde identificarea sistemului constă în determinarea coeficienților polinoamelor A, B, C, D și F:

$$A(z^{-1})y[k] = \frac{B(z^{-1})}{F(z^{-1})}u[k] + \frac{C(z^{-1})}{D(z^{-1})}e[k] \tag{6.1}$$

Unde $u[k]$ este intrarea, $y[k]$ ieșirea, iar $e[k]$ este zgomotul alb (eroarea de predicție).

6.2.1. Modelul ARX

Ecuația modelului:

$$A(z^{-1})y[k] = B(z^{-1})u[k - n_d] + e[k] \tag{6.2}$$

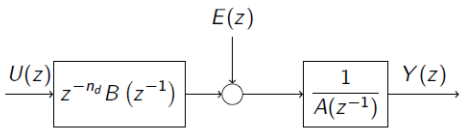

Figura 6.1: Structura corespunzătoare modelului ARX

Caracteristici:

- Perturbația intră în sistem prin ecuația erorii (equation error).
- Polinomul de la numitorul funcției de transfer a procesului (A) este identic cu cel al funcției de transfer a zgomotului.
- Se estimează parametrii polinoamelor A (ordin n_a) și B (ordin n_b), plus întârzierea n_d.
- Identificarea se realizează prin Metoda Celor Mai Mici Pătrate.

Un sistem identificat folosind metoda ARX trebuie validat prin autocorelație.

6.2.2. Modelul ARMAX

Reprezintă o extensie a modelului ARX care include o medie alunecătoare a zgomotului, oferind o flexibilitate mai mare în modelarea perturbațiilor.

Ecuația modelului:

$$A(z^{-1})y[k] = B(z^{-1})u[k - n_d] + C(z^{-1})e[k] \tag{6.3}$$

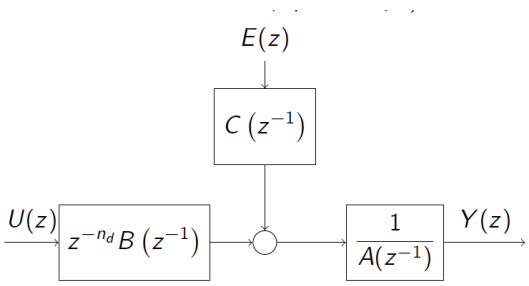

Figura 6.2: Structura corespunzătoare modelului ARMAX

Caracteristici:

- Polinomul $C(z^{-1})$ modelează partea de zgomot.
- Parametrii de structură:
  - $n_A = \deg A$ (numărul polilor);
  - $n_B = \deg B + 1$ (numărul zerourilor + 1);
  - $n_C = \deg C$ (dimensiunea ferestrei alunecătoare);
  - n_d numărul tacților de întârziere (interfațarea ADC/DAC și timpul mort).
- Identificarea se realizează prin Metoda Celor Mai Mici Pătrate (LSM).

Un sistem identificat folosind metoda ARMAX trebuie validat prin autocorelație.

6.2.3. Modelul OE (Output Error)

Pentru o identificare corectă, eroarea de predicție $\varepsilon[n]$ trebuie să fie necorelată cu ieșirea prezisă:

$$\lim_{n\to\infty} E\{\varepsilon[n]\hat{y}[n-i]\} = 0, \quad \forall i \tag{6.4}$$

Ceea ce înseamnă că un sistem identificat folosind metoda OE trebuie validat prin intercorelație. Metoda erorii de ieșire (Output Error) descrie doar partea deterministă a sistemului, neincluzând un model explicit al zgomotului.

Ecuația modelului:

$$y[k] = \frac{B(z^{-1})}{F(z^{-1})}u[k-n_d] + e[k] \tag{6.5}$$

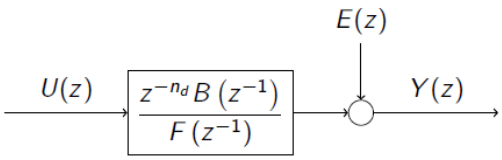

Figura 6.3: Structura corespunzătoare modelului OE

Caracteristici:

- Parametrii de structură:
  - $n_F = \deg F$ (numărul polilor);
  - $n_B = \deg B + 1$ (numărul zerourilor + 1);
  - n_d numărul tacților de întârziere (interfațarea ADC/DAC și timpul mort).
- Zgomotul nu este modelat ($H_{noise} = 1$), fiind considerat zgomot alb adăugat direct la ieșire.
- Modelul erorii de ieșire este neliniar în parametri deoarece regresorul $\varphi[n]$ depinde de valorile estimate $\hat{y}[n-i]$.

6.2.4. Modelul BJ (Box-Jenkins)

Box–Jenkins – model general ce descrie atât partea deterministă, cât și pe cea stohastică. Separarea modelului de zgomot permite o estimare mai precisă a perturbațiilor. Modelele ARX, ARMAX și OE sunt cazuri particulare ale structurii BJ.

Ecuația modelului:

$$y[k] = \frac{B(z^{-1})}{F(z^{-1})}u[k-n_d] + \frac{C(z^{-1})}{D(z^{-1})}e[k] \tag{6.6}$$

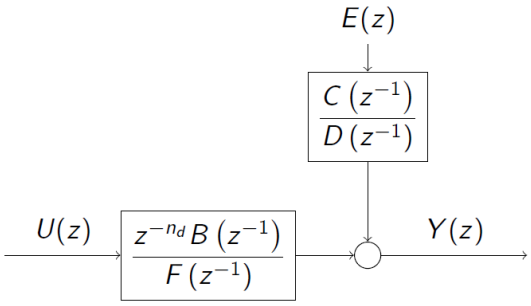

Figura 6.4: Structura corespunzătoare modelului Box-Jenkins

Caracteristici:

- Funcția de transfer a procesului (B/F) și cea a zgomotului (C/D) nu au polinoame comune.
- Permite o descriere foarte precisă atunci când zgomotul are o dinamică complexă, diferită de cea a sistemului.
- Necesită estimarea a 5 seturi de parametri:
  - $n_F = \deg F$: numărul polilor din partea deterministă;
  - $n_B = \deg B + 1$: numărul zerourilor din partea deterministă;
  - $n_C = \deg C$: numărul zerourilor din partea stohastică;
  - $n_D = \deg D$: numărul polilor din partea stohastică;
  - n_d: numărul tacților de întârziere din partea deterministă (timpul mort și interfațarea ADC/DAC).

Validarea modelelor BJ se face prin intercorelație, datorită lipsei componentei autoregresive comune.

6.2.5. Validarea Modelelor Identificate

Evaluarea gradului de suprapunere (FIT)

Acest criteriu oferă o măsură cantitativă intuitivă a calității modelului, exprimând procentual cât de fidel reușește ieșirea simulată să urmărească datele reale din setul de validare.

Analiza statistică a reziduurilor

Dincolo de simpla potrivire vizuală, un model valid trebuie să extragă toată informația utilă din date. Analiza reziduurilor verifică ipoteza că eroarea de predicție este un zgomot alb, folosind teste de corelație specifice:

- **Modelele ARX și ARMAX:** Fiind structuri care modelează explicit și zgomotul, acestea sunt validate prioritar prin **testul de autocorelație a erorii**.
- **Modelele OE (Output Error), BJ (Box-Jenkins) și IV4:** Deoarece separă dinamica procesului de cea a zgomotului, validarea lor se bazează pe **testul de intercorelație**.

- **Metodele pe subspații (N4SID) și eroarea de predicție (SSEST):** Pentru aceste abordări mai complexe, se consideră suficientă trecerea cu succes a cel puțin unuia dintre testele statistice (autocorelație sau intercorelație) pentru a valida modelul.

6.2.6. Tehnici de Rafinare a Modelelor

Dacă validarea inițială eșuează, se recomandă aplicarea unor tehnici de rafinare:

- **Detrending:** Eliminarea componentelor continue (DC) sau a trendurilor.
- **Decimare:** Reducerea frecvenței de eșantionare pentru a evidenția dinamica lentă.
- **Filtrare:** Aplicarea filtrelor pentru eliminarea zgomotului de înaltă frecvență.
- **Interschimbarea datelor:** Folosirea altui set pentru identificare vs. validare.
- **Creșterea complexității:** Mărirea ordinelor polinoamelor.
- **PEM:** Optimizarea parametrilor unui model deja estimat.

Capitolul 7. Proiectul 3-Calibrarea Semnalului SPAB

7.1. Scopul lucrării

Lucrarea curentă de proiect propune proiectarea și calibrarea semnalelor pseudoaleatoare binare (SPAB) pentru identificarea sistemelor dinamice utilizând metode parametrice.Se analizează problematica de calibrare a unui semnal de intrare adecvat pentru evidențierea unei dinamici aproximativ liniare.

7.2. Studiu de Caz: Convertor DC-DC ridicator de tensiune

7.2.1. Descrierea procesului fizic

Se prezintă un experiment de achiziție de date și identificare a modelului matematic pentru un circuit electric de comutație de tip convertor DC-DC ridicător de tensiune (*engl. boost*). Convertorul boost este des întâlnit în aplicații practice, precum la interfațarea cu panouri fotovoltaice pentru a extrage puterea maximă către consumatori.

În Figura 1 sunt ilustrate atât schema electrică de principiu a unui convertor boost, cât și un exemplu de realizare hardware a acestuia. Caracteristica neliniară intrare-ieșire este:

$$V_{out} = \frac{1}{1-\mu} V_{in} \tag{7.1}$$

unde $\mu \in [0, 1]$ este factorul de umplere al semnalului PWM (*engl. pulse width modulation*) care acționează asupra tranzistorului convertorului.

Considerând tensiunea de alimentare V_{in} fixată, sistemul dinamic are semnalul de comandă dat de factorul de umplere $\mu(t) \in [0, 1]$ și semnalul de ieșire dat de tensiunea la bornele impedanței de sarcină. EOF

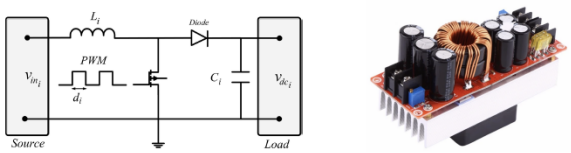

Figura 7.1: Convertor DC ridicator de tensiune

7.3. Proiectarea și Calibrarea Semnalului de Intrare

Pentru identificarea parametrică, s-a utilizat un semnal de tip SPAB suprapus peste punctul static de funcționare.

7.3.1. Prametrii Secventei SPAB

Parametrii generatorului pseudo-aleator au fost calibrati pornind de la timpul de urcare observat al sistemului:

```
t1=0.20;
N=4;

tr=0.02*2;
p=round(tr/N/Ts)
deltaT=p*(2^N-1)*Ts*2.5
```

Figura 7.2: Codul pentru calibrarea semnalului SPAB

Stabilizarea Inițială Variabila `t1 = 0.20` s definește intervalul de timp alocat sistemului pentru a atinge regimul staționar (punctul static de funcționare)

Configurarea Generatorului SPAB S-a ales un registru de deplasare cu **N = 4 biți**. Această valoare determină o lungime a secvenței pseudo-aleatoare de:

$$M = 2^N - 1 = 15 \text{ stări distincte} \tag{7.2}$$

Calibrarea Frecvenței (Parametrul p) Divizorul de frecvență p, a fost calculat pe baza timpului de ridicare ($t_r \approx 0.04$ s) determinat experimental.

Durata Experimentului Durata totală a semnalului SPAB (ΔT) a fost setată automat pentru a acoperi **2.5 perioade** complete ale secvenței:

$$\Delta T = 2.5 \cdot (p \cdot M \cdot T_s) \tag{7.3}$$

Semnalul rezultat este ilustrat ın figura de mai jos. Se observa palierul initial de asteptare (t1), urmat de rampa trapezoidala si apoi de secventa SPAB calibrata pe dinamica procesului.

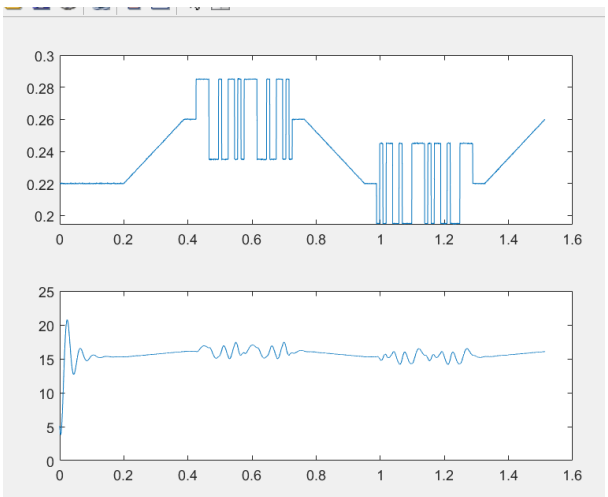

Figura 7.3: Semnalul de intrare calibrat si raspunsul sistemului

Capitolul 8. Proiectul4 - Identificarea Parametrica

8.1. Scopul lucrării

Lucrarea curentă își propune să aplice metodologiile de identificare parametrică,utilizând datele experimentale din lucrarea anterioară, în vederea construirii, rafinării și validării modelelor matematice ale sistemelor analizate.

Se urmărește utilizarea semnalelor de excitație deja proiectate și aplicarea funcțiilor standard din *System Identification Toolbox* pentru a fundamenta un model valid al procesului.

Se păstrează experimentul de achiziție de date pentru convertorul DC-DC boost .Se utilizează același semnal de intrare trapezoidal peste care s-a suprapus un semnal pseudoaleator binar. Se reutilizează schemele Simulink și fișierele MATLAB adiacente din lucrarea anterioară.

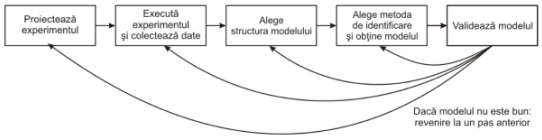

Figura 8.1: Pasi ientificare model matematic valid

8.1.1. Construirea seturilor de date de identificare și validare

Proiectarea experimentului, constând în calibrarea semnalului de intrare (semnal trapezoidal cu componentă SPAB suprapusă) în funcție de dinamica procesului, a fost realizată în etapa anterioară a proiectului.

Pentru procesul de modelare parametrică, datele experimentale achiziționate au fost structurate utilizând obiecte de tip `iddata` în mediul MATLAB. Această comandă (`data = iddata(y, u, Ts)`) permite encapsularea vectorilor de ieșire și intrare împreună cu perioada de eșantionare, facilitând separarea fluxului de date în două subseturi distincte:

- **Setul de Identificare:** utilizat pentru estimarea parametrilor modelului.
- **Setul de Validare:** utilizat pentru verificarea performanțelor modelului pe date necunoscute.

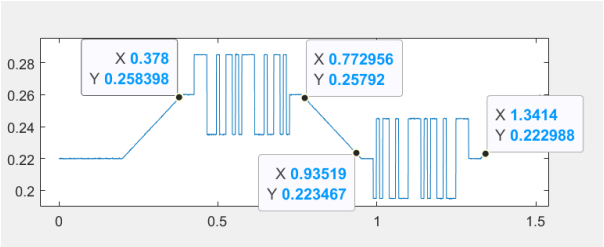

Figura 8.2: Selectia intervalelor de timp pentru identificare si validare

8.1.2. Metode de Pre-procesare

Procesul de identificare a necesitat pregătirea datelor brute prin următoarele etape:

1.Decimarea: S-a aplicat o decimare cu factorul $N_{dec} = 14$.

Factorul de decimare a fost determinat prin numararea numarului de esantioane dintr un impuls al semnalului de intrare.

2.Eliminarea Componentei Continue (Detrending): S-a eliminat valoarea medie din ambele semnale ($u - \text{mean}(u)$, $y - \text{mean}(y)$).

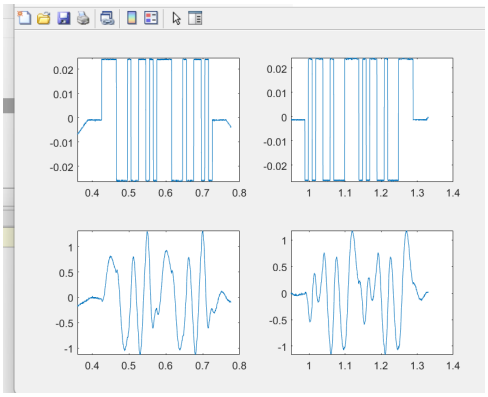

Figura 8.3: Datele pre-procesate. Sus: Detaliu utilizat pentru calculul factorului de decimare. Jos: Semnalele de identificare (stânga) și validare (dreapta), decimate și centrate pe zero

8.1.3. Alegerea Parametrilor de Structură

Selectarea ordinelor polinoamelor s-a făcut iterativ, pornind de la observația fizică a răspunsului sistemului (oscilant, sugerând ordin ≥ 2) și rafinând pe baza criteriului de potrivire (FIT) și a analizei reziduurilor.

- **Modelul ARMAX ([3, 1, 14, 2]):**
  - $n_a = 3$ (Poli): Un ordin 3 a fost necesar pentru a captura complexitatea oscilațiilor amortizate observate în răspuns. Un ordin 2 s-a dovedit insuficient pentru a modela complet dinamica.
  - $n_b = 1$ -numarul de zerouri $n_k = 2$ (eșantioane decimate) compensează timpul mort observat între aplicarea treptei și răspunsul ieșirii.
  - $n_c = 14$ (Zgomot): S-a ales un ordin ridicat pentru modelul zgomotului

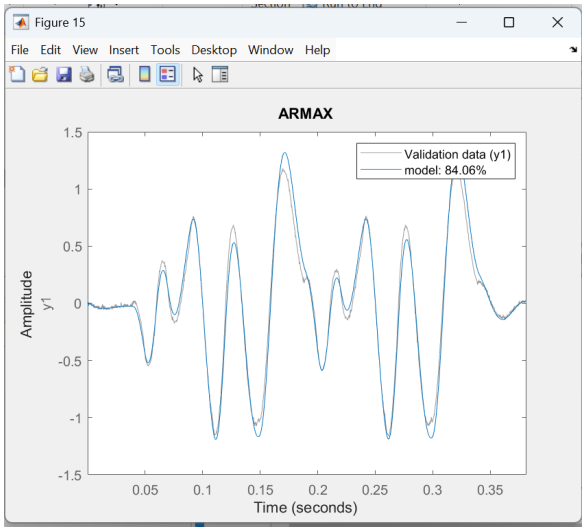

Figura 8.4: FIT

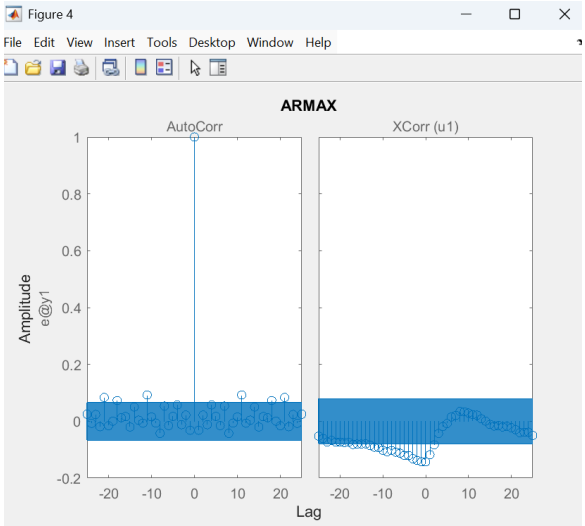

Figura 8.5: Validarea modelului ARMAX-prin autocorelatie

- **Modelul Box-Jenkins (BJ [2, 8, 2, 2, 2]):**
  S-a optat pentru structura BJ pentru a decupla complet dinamica sistemului (B/F) de cea a zgomotului (C/D). Pentru acest experiment, s-a identificat o structură optimă cu vectorul de ordine **[2, 8, 2, 2, 2]**. Semnificația fizică și matematică a acestor parametri este următoarea:

- $n_a = 2$**:** Ordinul sistemului
- $n_b = 2$**:** Numărul de coeficienți ai numărătorului funcției de transfer a procesului
- $n_c = 8$**:** Ordinul numărătorului funcției de transfer a zgomotului
- $n_d = 2$**:** Ordinul numitorului funcției de transfer a zgomotului
- $n_f = 2$**:** Ordinul numitorului funcției de transfer a procesului
- $n_k = 2$**:** Întârzierea (timpul mort) exprimată în perioade de eșantionare

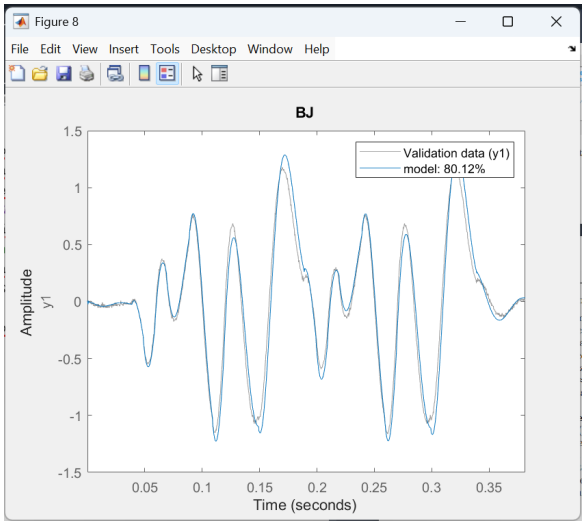

Figura 8.6: FIT

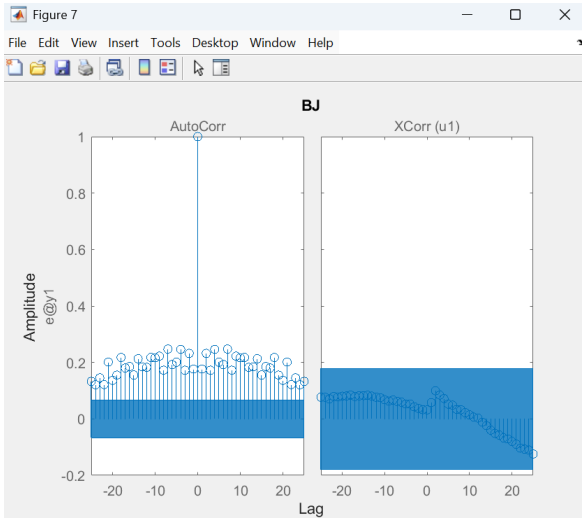

Figura 8.7: Validarea modelului bj prin intecorelatie

- **Modelul State-Space (ssest, ordin 1:4):** S-a utilizat algoritmul N4SID pentru a

determina automat ordinul optim al stărilor în intervalul 1-4, bazat pe valorile singulare ale matricei Hankel.

Spre deosebire de modelele polinomiale (ARX, ARMAX, BJ) care descriu relația intrare-ieșire printr-o funcție de transfer unică, modelele în spațiul stărilor descriu sistemul printr-un set de variabile interne numite *stări*. Această reprezentare este fundamentală în teoria sistemelor moderne și oferă o descriere mai completă a dinamicii interne.

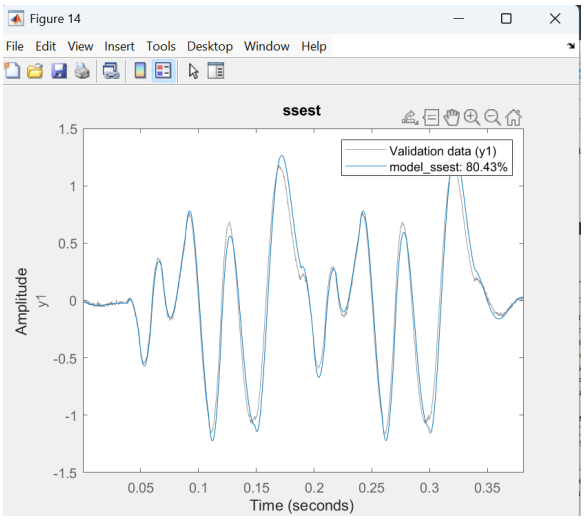

Figura 8.8: FIT

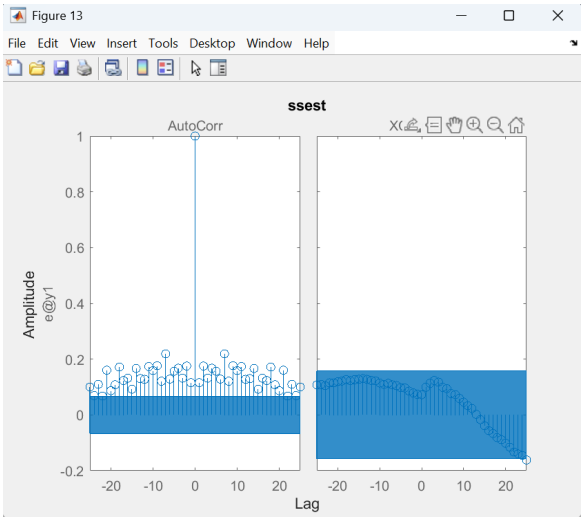

Figura 8.9: Validarea modelului SSEST-prin intercorelatie

8.1.4. Analiza Proprietăților Modelelor Valide

După identificare, s-a analizat modelul rezultat pentru a verifica plauzibilitatea fizică:

- **Stabilitate:** S-au verificat polii funcției de transfer continue H_s folosind comanda `zpk(Hs)`. Toți polii au părți reale negative (sau module subunitare în discret), confirmând că modelul identificat este stabil, așa cum este și sistemul fizic (convertorul).
- **Regim Staționar:** Câștigul static (DC Gain) al modelului a fost verificat implicit prin suprapunerea grafică pe datele de validare. Faptul că semnalul simulat y_{sim} urmărește media datelor reale indică un câștig static corect identificat.
- **Singularități (Poli și Zerouri):** Prezența unor perechi de poli complex-conjugați în H_s justifică comportamentul oscilant al sistemului. Poziția lor determină frecvența naturală și factorul de amortizare al convertorului.

- **Metrica de Performanță (eMPN)**

Pentru evaluarea cantitativă, s-a calculat Eroarea Medie Pătratică Normalizată (eMPN) în procente:

$$eMPN = \frac{||y_{vd} - y_{sim}||}{||y_{vd} - \text{mean}(y_{vd})||} \times 100 \tag{8.1}$$

Această valoare (calculată în cod la finalul fiecărei secțiuni) reprezintă procentul din variația ieșirii.

O valoare mică a eMPN (complementară cu FIT-ul afișat de `compare`) confirmă validitatea modelului. De exemplu, un FIT de 80% corespunde aproximativ unui eMPN de 20%.

Tabela 8.1: Centralizatorul proprietăților fizice (Echivalență în planul s)

Model	**Funcția de Transfer** $H(s)$	**Poli** (s)	**Câștig** (K)	**Eroare**
ARMAX	$\frac{5.44s^2+6.62\cdot10^4s+2.66\cdot10^8}{s^3+536s^2+5.85\cdot10^4s+1.09\cdot10^7}$	-460.5, cplx	24.31	15.95%
BJ	$\frac{-1133s+5.12\cdot10^5}{s^2+74.88s+2.29\cdot10^4}$	$-37.4 \pm 146.4i$	22.41	19.44%
SSEST	$e^{-0.00025s}\,\frac{5.44(s^2+1.22\cdot10^4s+4.89\cdot10^7)}{(s+460.5)(s^2+75.4s+2.37\cdot10^4)}$	-460.5, cplx	24.31	19.59%

8.2. Modelul Output Error (OE)

Ca o alternativă la structurile care modelează explicit zgomotul, s-a testat metoda Output Error (OE). Aceasta are avantajul decuplării funcției de transfer a procesului de cea a zgomotului, asumând o structură simplă a perturbațiilor ($H(z) = 1$).

- **Autocorelația (stânga):** Iese semnificativ din intervalul de încredere. Acest lucru este așteptat și acceptat, deoarece structura OE nu dispune de parametri (polinoamele C sau D) pentru a modela complexitatea zgomotului real, lăsând componenta colorată în reziduuri.
- **Intercorelația (dreapta):** Se încadrează în limitele impuse. Acesta este **criteriul fundamental de validare** pentru modelele de tip Output Error, garantând că eroarea de predicție nu este corelată cu intrarea și că modelul a extras toată informația dinamică relevantă din datele experimentale.

Deși din punct de vedere statistic zgomotul nu este alb, modelul OE este considerat **valid** pentru simulare și proiectarea regulatorului, oferind un grad ridicat de suprapunere (FIT) pe datele de validare .

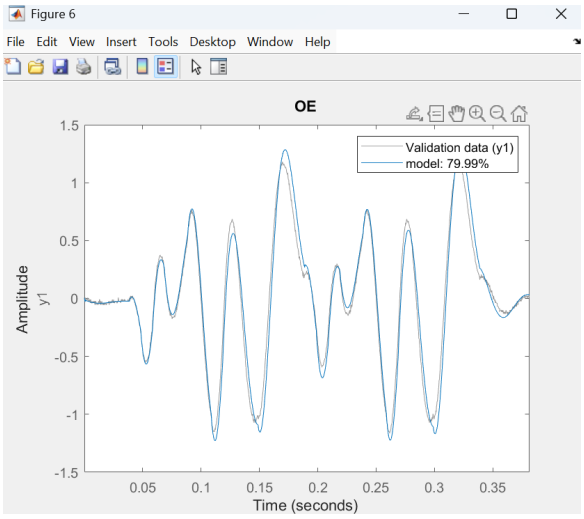

Figura 8.10: FIT

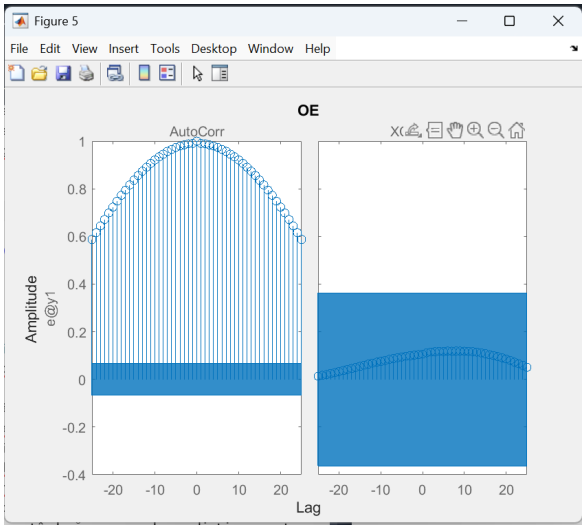

Figura 8.11: Validarea modelului OE-prin intercorelatie

Capitolul 9. Sinteza Rezultatelor și Analiza Comparativă

Acest capitol prezintă sinteza rezultatelor obținute pe parcursul lucrării, evidențiind distincțiile metodologice dintre abordarea neparametrică (utilizată în primele etape) și cea parametrică (utilizată în etapa curentă). Analiza este structurată pe cele două studii de caz: identificarea circuitului hidraulic și modelarea analitică a convertorului DC-DC.

9.1. Analiza Comparativă 1: Metode Neparametrice (Circuit Hidraulic)

În prima parte a activității de laborator, obiectivul a fost determinarea parametrilor fizici ($K, T1$,$T2$) pentru un **circuit hidraulic**. S-au comparat două metode clasice, bazate pe analiza directă a răspunsului sistemului la semnale de test specifice.
Rezultatele comparative sunt:

- **Metoda Răspunsului la Treaptă:** Această metodă a oferit o vizualizare clară a regimului tranzitoriu. Deși simplistă, liniarizarea anvelopei a permis o estimare rapidă a constantei de timp, fiind însă sensibilă la zgomotul de măsurare specific senzorilor hidraulici.
- **Metoda Răspunsului în Frecvență (Chirp):** A permis explorarea comportamentului sistemului pe o bandă largă de frecvențe. Totuși, neliniaritățile circuitului hidraulic au introdus distorsiuni care au făcut dificilă extragerea precisă a diagramei Bode fără o pre-procesare complexă.

Discuție și Concluzie: Analizând cele două abordări aplicate circuitului hidraulic, **Metoda Răspunsului la Treaptă** s-a dovedit a fi mai robustă în acest caz specific. Deși semnalul Chirp oferă teoretic mai multă informație spectrală, pentru un sistem hidraulic dominat de o dinamică de ordinul I sau II cu timp mort, simplitatea treptei a minimizat erorile de interpretare. Semnalul Chirp a generat o eroare de validare ușor mai ridicată din cauza dificultății de a menține un punct static de funcționare constant pe durata variației de frecvență.

9.2. Analiza Comparativă 2: Metode Parametrice (Convertor DC-DC)

În etapa curentă, pentru sistemul cu Convertor DC, cerințele de precizie au impus utilizarea identificării parametrice. Procesul s-a bazat pe un semnal de intrare de tip SPAB.
Performanțele modelelor obținute sunt centralizate în clasamentul de mai jos:

Tabela 9.1: Clasamentul performanței modelelor parametrice (Convertor)

Loc	Model	Eroare (eMPN)	Observații
1	**ARMAX**	**15.95%**	Cel mai bun echilibru dinamică-zgomot.
2	Box-Jenkins	19.44%	Structură flexibilă, dar ușor supra-parametrizată.
3	SSEST	19.59%	Model compact în spațiul stărilor.

Concluzie: Spre deosebire de așteptările teoretice unde modelul Box-Jenkins este adesea superior datorită independenței dintre modelul sistemului și cel al zgomotului, în cazul acestui convertor, **modelul ARMAX** a oferit cea mai bună performanță (cea mai mică eroare eMPN). Acest lucru sugerează că perturbările sistemului au o dinamică comună cu cea a procesului (împart aceiași poli), ceea ce favorizează structura ARMAX.

9.2.1. Sinteză Metodologică

Privind în ansamblu cele două abordări (Hidraulic vs. Convertor), se pot desprinde concluzii importante privind aplicabilitatea lor:

1. **Metodele Neparametrice** (aplicate circuitului hidraulic) sunt intuitive și oferă o diagnoză rapidă "la prima vedere". Sunt ideale pentru procese lente, industriale, unde se dorește doar o reglare PI sumară.
2. **Metodele Parametrice** (aplicate convertorului) sunt "instrumente de precizie". Deși necesită un efort de configurare mai mare (alegerea ordinelor, preprocesare, decimare), ele sunt capabile să extragă modele matematice de mare finețe (cu erori sub 20% pe date reale zgomotoase), fiind indispensabile pentru proiectarea regulatoarelor avansate.

9.2.2. Concluzii Finale

Lucrarea a demonstrat procesul complet de identificare a sistemelor. Pentru convertorul DC-DC, analiza a relevat un sistem stabil dar puternic oscilant (cu poli complex-conjugați dominanți), comportament capturat cel mai fidel de modelul **ARMAX**. Această funcție de transfer va constitui baza matematică solidă pentru etapele viitoare de proiectare a strategiei de control automat.

Bibliografie

[1] Lucian Bușoniu, *Curs: Introducere în Identificarea Sistemelor și Analiza de Corelație*, Universitatea Tehnică din Cluj-Napoca, Facultatea de Automatică și Calculatoare, 2025.

[2] Mircea Suscă, *Curs 5: Intrări și Filtrare (IS_C5_intrari&filtrare.pdf)*, Universitatea Tehnică din Cluj-Napoca, 2025.

[3] Mircea Suscă, *Curs 6: Funcții de corelație și modele FIR (IS_C6_xcorr&FIR.pdf)*, Universitatea Tehnică din Cluj-Napoca, 2025.

[4] Mircea Suscă, *Curs 7: Identificarea online (IS_C7_idpoly_online.pdf)*, Universitatea Tehnică din Cluj-Napoca, 2025.

[5] Mircea Suscă, *Curs 8: Identificarea offline și rafinarea modelelor (IS_C8_id_offline&rafinare.pdf)*, Universitatea Tehnică din Cluj-Napoca, 2025.

[6] Mircea Suscă, *Curs 10: Identificarea în spațiul stărilor (IS_C10_ss.pdf)*, Universitatea Tehnică din Cluj-Napoca, 2025.

[7] Mircea Suscă, *Îndrumător Proiect 2: Analiza Corelației*, Universitatea Tehnică din Cluj-Napoca, 2025.

[8] Mircea Suscă, *Îndrumător Proiect 3: Metode Neparametrice*, Universitatea Tehnică din Cluj-Napoca, 2025.

[9] Mircea Suscă, *Îndrumător Proiect 4: Calibrarea semnalelor pseudoaleatoare binare (IS_P4.pdf)*, Universitatea Tehnică din Cluj-Napoca, 2025.

[10] Mircea Suscă, *Îndrumător Proiect 5: Identificarea sistemelor utilizând metode parametrice (IS_P5.pdf)*, Universitatea Tehnică din Cluj-Napoca, 2025.

[11] The MathWorks Inc., *System Identification Toolbox User's Guide*, Natick, MA, United States. Disponibil online: `https://www.mathworks.com/help/ident/`.

[12] The MathWorks Inc., *Documentation for ARMAX (Autoregressive Moving Average with Exogenous Input) Model Estimation*, System Identification Toolbox.

[13] The MathWorks Inc., *Documentation for SSEST and N4SID (State-Space Model Estimation)*, System Identification Toolbox.